

Classificazione della qualità del vino rosso mediante modelli di Machine Learning

Gruppo 19 — Business Intelligence per Big Data, Politecnico di Torino, AA 2025–2026

Sommario—Il progetto affronta un problema di classificazione supervisionata della qualità del vino rosso. L'obiettivo è predire la variabile `WineQuality`, espressa su scala discreta da 3 a 8, a partire da 11 misurazioni chimico-fisiche e 3 feature derivate. La sperimentazione confronta due insiemi di variabili: `FULL`, che include le feature derivate, e `NOCORR`, che utilizza soltanto le variabili originali. Sono state considerate quattro famiglie di algoritmi: Gaussian Naive Bayes, Decision Tree, Random Forest e Support Vector Machine; selezionate tramite Stratified 3-Fold Cross Validation sul training set filtrato. Il test set è stato utilizzato una sola volta per la valutazione finale. A causa del forte sbilanciamento della variabile target, la metrica primaria adottata è la Macro F1, affiancata dall'Accuracy e, sul test set, da Macro Precision e Macro Recall. I risultati mostrano che la Random Forest con feature set `FULL` è il modello più competitivo nel task a 6 classi, pur con prestazioni ancora limitate sulle classi estreme.

I. INTRODUZIONE

La valutazione della qualità del vino rosso è tradizionalmente affidata ad analisi sensoriali condotte da esperti, procedure fondamentali nel processo enologico ma costose, soggettive e difficili da standardizzare su larga scala. In un contesto di Business Intelligence, modelli predittivi basati su variabili chimico-fisiche di laboratorio possono rappresentare un valido supporto decisionale per una prima classificazione quantitativa dei campioni. In questo lavoro il problema è formulato come una classificazione supervisionata multiclasse, nella quale il target `WineQuality` assume valori interi da 3 a 8. L'obiettivo è confrontare diversi algoritmi predittivi e verificare se essi superino realmente una baseline maggioritaria, evitando interpretazioni fuorvianti fondate sulla sola Accuracy. Per questa ragione, la metrica primaria è la Macro F1, che attribuisce uguale importanza a tutte le classi, comprese quelle minoritarie.

II. ANALISI DEI DATI

Il dataset utilizzato comprende un training set di 1024 osservazioni e un test set di 256 osservazioni. Nel training set è presente la variabile `Synthetic_Noise_Flag`, che identifica osservazioni rumorose. Nella pipeline definitiva il filtro `Synthetic_Noise_Flag = 0` è applicato esclusivamente al training set, che si riduce a 879 osservazioni. Il test set, invece, non viene filtrato nella valutazione principale e viene mantenuto invariato, in modo da simulare dati futuri non preventivamente puliti. Va tuttavia osservato che esso contiene 48 osservazioni marcate come rumorose, pari al 18,75% del totale; le metriche finali devono quindi essere interpretate come una stima conservativa della capacità di generalizzazione del




Figura 1. Distribuzione della variabile target `WineQuality` nel training set filtrato. Le classi centrali 5 e 6 risultano nettamente prevalenti, mentre le classi estreme 3 e 8 sono fortemente sottorappresentate.

sistema. Il filtro `Synthetic_Noise_Flag = 0` sul test set è utilizzato soltanto in un'analisi secondaria di robustezza.

La variabile target `WineQuality` assume valori interi da 3 a 8. La distribuzione delle classi nel training set filtrato è fortemente sbilanciata: la classe 3 contiene soltanto 3 osservazioni, la classe 4 ne contiene 29, la classe 5 ne contiene 375, la classe 6 ne contiene 353, la classe 7 ne contiene 108 e la classe 8 ne contiene 11. La Fig. 1 mostra graficamente tale distribuzione.

Lo sbilanciamento del target condiziona l'intero protocollo sperimentale. In primo luogo, rende inadeguata una valutazione basata esclusivamente sull'Accuracy, poiché un modello potrebbe ottenere una prestazione apparentemente elevata limitandosi a predire la classe più frequente. In secondo luogo, impone l'utilizzo di una Stratified K-Fold Cross Validation con $K = 3$, poiché un numero maggiore di fold rischierebbe di generare partizioni prive di esempi della classe più rara. Per questi motivi, la metrica primaria adottata nel lavoro è la Macro F1, che calcola la media dell'F1-score sulle classi assegnando a ciascuna lo stesso peso, indipendentemente dalla numerosità.

La Tab. I riassume la diagnostica principale del dataset dopo il preprocessing.

Il dataset contiene 11 variabili chimico-fisiche originali: `fixed_acidity`, `volatile_acidity`, `citric_acid`, `residual_sugar`, `chlorides`, `free_sulfur_dioxide`, `total_sulfur_dioxide`, `density`, `pH`, `sulphates` e `alcohol`. A queste si

Tabella I
DIAGNOSTICA DEL DATASET DOPO IL PREPROCESSING.

Aspetto	Valore	Implicazione
Train iniziale	1024 oss.	Base prima del filtro
Train filtrato	879 oss.	Rumore rimosso dal train
Test set	256 oss.	Valutazione finale
Rumore nel test	48 oss.	18,75% del totale
Classe rara	3 oss.	CV limitata a $K = 3$
Baseline 6 classi	Acc. 42,66%; F1 9,97%	Accuracy fuorviante

le colonne sono convertite in formato numerico, trasformando eventuali valori non numerici in valori mancanti. In secondo luogo, il filtro sul rumore è applicato esclusivamente al training set. Infine, le feature derivate con formula nota sono ricostruite solo nelle celle mancanti, evitando di sovrascrivere i valori già presenti.

Le due feature derivate ricostruite sono definite dalle seguenti relazioni:

$$\text{Alcohol_Density_Ratio} = \frac{\text{alcohol}}{\text{density}} \quad (1)$$

$$\text{Acidity_Sulfur_Interaction} = \text{fixed_acidity} \times \text{sulphates} \quad (2)$$

La variabile *Volatile_Enhanced* non viene ricalcolata, essendo un indicatore binario già presente nel dataset. Dopo la ricostruzione delle feature derivate secondo le Eq. (1) e (2), il dataset non presenta valori mancanti residui.

Sono state considerate quattro famiglie di algoritmi. Il Gaussian Naive Bayes è utilizzato come modello probabilistico semplice e robusto, privo di iperparametri critici. Il Decision Tree è impiegato come modello interpretabile, con $\text{max_depth} = 10$ e $\text{min_samples_leaf} = 5$. La Random Forest è valutata come modello ensemble robusto rispetto a rumore, interazioni non lineari e instabilità dei singoli alberi. Infine, le Support Vector Machine sono testate sia con kernel lineare sia con kernel RBF.

Per i modelli ad albero e per le SVM è stato impostato $\text{class_weight} = \text{balanced}$, così da riequilibrare la funzione obiettivo in modo inversamente proporzionale alla frequenza delle classi. Per i modelli sensibili alla scala delle variabili, cioè Gaussian Naive Bayes e SVM, la standardizzazione è stata inserita in una Pipeline; in questo modo media e deviazione standard sono stimate esclusivamente sul training fold durante la Cross Validation, evitando leakage informativo.

Il protocollo di validazione prevede una Stratified 3-Fold Cross Validation sul training set filtrato. La selezione del modello e degli iperparametri avviene esclusivamente in questa fase. Solo successivamente ogni modello viene riaddestrato sull'intero training set e valutato una sola volta sul test set. Il test set non è quindi utilizzato né per scegliere l'algoritmo né per fissare gli iperparametri. Le metriche considerate in Cross Validation sono Accuracy e Macro F1, mentre sul test set sono calcolate anche Macro Precision e Macro Recall.

IV. RISULTATI SPERIMENTALI

A. Risultati in Cross Validation

La Tab. II riporta i principali risultati ottenuti in Cross Validation. I modelli Decision Tree e SVM lineare sono stati valutati con lo stesso protocollo, ma non vengono inclusi nella tabella sintetica poiché sistematicamente inferiori rispetto alle alternative riportate.

Il modello migliore in termini di Macro F1 è la Random Forest con feature set FULL, che raggiunge una Macro F1 media pari a 22,57%. La Random Forest NOCORR ottiene una Macro F1 inferiore, pari a 20,36%, indicando che le feature




Figura 2. Matrice di correlazione di Pearson tra le feature del dataset. Le correlazioni elevate tra alcune variabili derivate e le variabili originali motivano il confronto tra il feature set completo FULL e il feature set ridotto NOCORR.

aggiungono 3 feature derivate:

Acidity_Sulfur_Interaction,
Alcohol_Density_Ratio e *Volatile_Enhanced*.

L'analisi di correlazione di Pearson, riportata in Fig. 2, evidenzia relazioni elevate tra alcune feature derivate e le variabili originali da cui discendono. In particolare, *Alcohol_Density_Ratio* risulta fortemente correlata con *alcohol*, *Volatile_Enhanced* con *volatile_acidity*, e *Acidity_Sulfur_Interaction* con *sulphates* e *fixed_acidity*. Per verificare se le feature derivate aggiungano informazione utile oppure introducano ridondanza, sono stati confrontati due scenari sperimentali: *FULL_with_correlation*, che utilizza tutte le 14 feature, e *NOCORR_without_derived*, che utilizza soltanto le 11 variabili chimico-fisiche originali.

III. METODOLOGIA

La pipeline è stata progettata con due obiettivi principali: preservare l'informazione contenuta nel dataset e impedire ogni forma di leakage tra training e test. Il preprocessing è articolato in tre fasi. In primo luogo, i file Excel sono caricati e

Tabella II
PRINCIPALI RISULTATI IN CROSS VALIDATION SUL TASK A 6 CLASSI,
ESPRESSI COME MEDIA $\pm$ DEVIAZIONE STANDARD TRA FOLD.

Task	Mod.	Set	Acc.	Macro F1
6 cl.	RF	FULL	38,79 $\pm$ 2,59	22,57 $\pm$ 2,59
6 cl.	RF	NOCORR	37,09 $\pm$ 0,98	20,36 $\pm$ 0,94
6 cl.	SVM RBF	NOCORR	33,56 $\pm$ 1,06	18,16 $\pm$ 1,55
6 cl.	NB	FULL	43,34 $\pm$ 1,00	17,56 $\pm$ 1,10
6 cl.	NB	NOCORR	44,48 $\pm$ 0,16	17,18 $\pm$ 0,50
6 cl.	Baseline	–	42,66 $\pm$ 0,00	9,97 $\pm$ 0,00




Figura 3. Confronto tra Accuracy e Macro F1 in Cross Validation per i modelli valutati sul task a 6 classi. La figura evidenzia la distanza tra prestazioni misurate tramite Accuracy e prestazioni misurate tramite Macro F1, confermando la necessità di adottare la Macro F1 come metrica primaria.

derivate forniscono un contributo utile, pur in presenza di correlazione con alcune variabili originali.

Il confronto con la baseline maggioritaria è particolarmente rilevante. La baseline ottiene una Accuracy pari a 42,66%, superiore a quella della Random Forest FULL, ma una Macro F1 pari soltanto a 9,97%. Ciò conferma che l'Accuracy, in presenza di classi sbilanciate, può risultare fuorviante: un modello che predice sistematicamente la classe prevalente può apparire competitivo in termini di Accuracy, pur non riconoscendo correttamente le classi minoritarie. La Fig. 3 mostra il confronto completo tra Accuracy e Macro F1 per i principali modelli e feature set.

La Fig. 4 sintetizza il confronto tra il miglior modello selezionato in Cross Validation e la baseline maggioritaria. La Random Forest FULL più che raddoppia la Macro F1 della baseline, passando da 9,97% a 22,57%.

B. Valutazione finale sul test set

Dopo la fase di Cross Validation, i modelli sono stati riaddestrati sull'intero training set filtrato e valutati una sola volta sul test set. I risultati principali sono riportati nella Tab. III.

Anche sul test set la Random Forest FULL risulta il modello più competitivo in termini di Macro F1, con un valore pari a 19,44%. La Random Forest NOCORR è molto vicina, con Macro F1 pari a 19,18%, mentre la SVM RBF NOCORR raggiunge 18,31%. La baseline maggioritaria mantiene una




Figura 4. Confronto tra il miglior modello selezionato in Cross Validation e la baseline maggioritaria. La Random Forest con feature set FULL ottiene una Macro F1 nettamente superiore alla baseline, nonostante quest'ultima presenti una Accuracy apparentemente competitiva.

Tabella III
PRINCIPALI RISULTATI SUL TEST SET NEL TASK A 6 CLASSI.

Task	Mod.	Set	Acc.	F1	Prec.	Rec.
6 cl.	RF	FULL	38,67	19,44	20,19	19,96
6 cl.	RF	NOCORR	35,55	19,18	19,37	19,82
6 cl.	SVM RBF	NOCORR	33,98	18,31	18,95	19,99
6 cl.	NB	NOCORR	44,14	17,28	16,85	18,16
6 cl.	Baseline	–	42,97	10,02	–	–

Accuracy elevata, pari a 42,97%, ma ottiene una Macro F1 di appena 10,02%, confermando l'assenza di reale capacità discriminante sulle classi meno frequenti.

L'analisi per classe mostra che il modello riconosce soprattutto le classi centrali. La Random Forest FULL ottiene F1 pari a 42,6% sulla classe 5 e 49,5% sulla classe 6, mentre raggiunge 18,4% sulla classe 7 e valori nulli sulle classi estreme 3 e 8. Questo risultato è coerente con la distribuzione del target: le classi centrali sono molto più rappresentate, mentre le classi estreme dispongono di pochissimi esempi. La Fig. 5 riporta la confusion matrix della Random Forest FULL sul test set.

Come analisi secondaria, la valutazione è stata ripetuta sul solo sottoinsieme pulito del test set, costituito da 208 osservazioni con `Synthetic_Noise_Flag` = 0. In questo scenario la Random Forest FULL ottiene Accuracy pari a 40,38% e Macro F1 pari a 20,14%. Il miglioramento rispetto al test set completo suggerisce che la presenza di rumore nel test deprime lievemente le prestazioni, ma non altera le conclusioni generali del lavoro.

C. Sensitivity analysis della Random Forest

Il comportamento della Random Forest è stato approfondito mediante una sensitivity analysis sugli iperparametri principali. Sono state considerate le combinazioni di `n_estimators` $\in \{100, 300, 500\}$, `max_depth` $\in \{5, 10, 20, \text{None}\}$ e `min_samples_leaf` $\in \{1, 4, 10\}$, per un totale di 36 configurazioni per ciascun feature set.

La Tab. IV riporta alcune configurazioni rappresentative. La migliore configurazione per Macro F1 è risultata quella basata su feature set FULL, con `n_estimators` =




Figura 5. Confusion matrix della Random Forest con feature set FULL sul test set. Il modello concentra la maggior parte delle predizioni sulle classi centrali, mentre mostra difficoltà nel riconoscere le classi estreme, coerentemente con la forte scarsità di osservazioni per tali classi.

Tabella IV
CONFIGURAZIONI RAPPRESENTATIVE DELLA SENSITIVITY ANALYSIS DELLA RANDOM FOREST IN CROSS VALIDATION SUL TASK A 6 CLASSI.

Set	n	depth	msl	Macro F1
FULL	100	5	4	22,57
NOCORR	500	5	10	22,04
NOCORR	500	5	4	21,93
FULL	300	5	4	21,20
FULL	500	20	1	15,81

100, $\text{max_depth} = 5$ e $\text{min_samples_leaf} = 4$, che raggiunge una Macro F1 pari a 22,57%.

I risultati evidenziano un trade-off netto tra Accuracy complessiva e bilanciamento tra classi. Configurazioni più profonde possono aumentare l'Accuracy, ma tendono a peggiorare la Macro F1, probabilmente perché si adattano maggiormente alle classi prevalenti. Al contrario, profondità ridotte agiscono da regolarizzatore e favoriscono una distribuzione più equilibrata delle predizioni. La Fig. 6 mostra l'andamento della Macro F1 media in Cross Validation al variare del numero di alberi e della profondità massima.

V. CONCLUSIONI

I risultati confermano che la classificazione della qualità del vino rosso è fortemente condizionata dallo sbilanciamento della variabile target. Nel task a 6 classi, la Random Forest con feature set FULL rappresenta il modello più competitivo in termini di Macro F1, sia in Cross Validation sia nella valutazione finale sul test set. Il vantaggio rispetto alla baseline maggioritaria è netto se misurato tramite Macro F1, mentre non emerge dalla sola Accuracy; ciò conferma la scelta metodologica di adottare la Macro F1 come metrica primaria.




Figura 6. Sensitivity analysis della Random Forest nel task a 6 classi. Le curve mostrano la Macro F1 media in Cross Validation al variare di $n_estimators$, con una curva per ciascun valore di max_depth ; i valori sono mediati su min_samples_leaf .

Nonostante il miglioramento rispetto alla baseline, le prestazioni assolute restano contenute, soprattutto sulle classi estreme. Il modello discrimina meglio le classi centrali 5 e 6, mentre fatica a riconoscere le classi 3 e 8, caratterizzate da pochissimi esempi. Il sistema deve quindi essere interpretato come uno strumento di supporto allo screening preliminare e non come sostituto del giudizio esperto dell'enologo.

Dal punto di vista applicativo, un modello di questo tipo potrebbe essere integrato in un processo di controllo qualità data-driven, mostrando per ogni lotto la classe prevista, il livello di confidenza, le variabili chimico-fisiche più critiche e il confronto con lotti storici simili. In prospettiva, il lavoro potrebbe essere esteso con l'integrazione di variabili oggi assenti, quali vitigno, area geografica, annata, condizioni di fermentazione e dati meteorologici. Sul piano modellistico, un'estensione naturale consiste nell'utilizzo di approcci ordinali, più coerenti con la natura ordinata della variabile WineQuality: un errore tra qualità 5 e 6 è infatti meno grave di un errore tra qualità 3 e 8.

VI. CONTRIBUTI

Il lavoro è stato svolto congiuntamente dal gruppo, dalla definizione del preprocessing alla valutazione dei modelli e all'interpretazione dei risultati.